

• 발표 · Research Progress

PGAL · Patch-Grounded Attribute Localization

Compositional Zero-Shot Learning CZSL

이미지의 '어디를 볼지'를 학습하는 새 접근 (PGAL)

KimDongKi

한양대학교 MMAI LAB · 2026

사진 한 장 → “어떤 상태의 어떤 사물인가”

- **속성**(상태) 빨간 · 잘린 × **사물** 사과 · 토마토 = **조합**
- 학습 땐 **빨간 사과 · 초록 토마토**만 봄
- 테스트에선 **빨간 토마토** — 처음 보는 조합을 맞혀야 함

핵심 질문 — “빨강도 알고 토마토도 아는데, red tomato를 한 번도 본 적 없을 때 맞힐 수 있는가?”

사람에겐 쉽지만, 기계엔 왜 어려운지가 다음 장.

학습에서 본 조합 (SEEN)

red apple

green tomato

sliced apple

테스트 — 처음 보는 조합

red tomato ?

sliced tomato ?

→ 속성·사물을 분해하고 **재조합** 해서 맞힌다

성능이 막히는 3가지 지점

1 상태가 사물 따라 뒀판

같은 '젖은'도 젖은 강아지 / 젖은 숲 / 젖은 모래에서 시각적으로 전혀 다름


2 형제 상태 구분 • ★ 이 발표의 키워드

sliced(잘린) vs diced(깍둑썬) vs mashed(으깬) — 미세한 시각 차이


3 본 조합에 과적합하면 안 본 조합이 무너짐

seen에만 맞추면 unseen이 붕괴 — 둘 사이의 trade-off가 본질

①의 예시 — 같은 속성, 다른 모습



wet dog



wet forest



wet sand

②(형제 상태)가 끝까지 이야기의 중심이 된다.

평가의 두 가지 축

① seen / unseen 을 같이 본다

본 조합(seen) 정확도와 **안 본 조합**(unseen) 정확도를 함께 — 한쪽만 높으면 안 됨.

HM(둘의 균형) · **AUC**(전 구간 종합)로 요약.

② top-1 vs top-5

top-1 = 1순위 답이 정답인 비율

top-5 = 정답이 상위 5개 안에 있는 비율

이 **top-1 ↔ top-5 격차**가 연구 전체를 관통하는 실이 된다 (슬라이드 9에서 다시 등장).

정답 = diced tomato 일 때

- | | | |
|----|---------------|----------------|
| 1. | sliced tomato | × top-1 실패 |
| 2. | diced tomato | ✓ 정답 (top-5 안) |
| 3. | mashed tomato | |

정답을 **5개 안엔** 넣어두지만, **1등을 못 고른다** — 형제 상태끼리 헛갈린다.

CLIP, 그리고 baseline Troika

출발점 — CLIP

이미지와 문장을 **같은 공간**에 올림. “a photo of red tomato”와 사진을 비교해 가장 맞는 문장을 고른다.

기존 흐름

CLIP의 이미지 쪽은 **그대로** 두고, **텍스트 쪽만** 학습·정교화한다.

Troika (CVPR'24 · 본 연구 baseline)

조합 / 속성 / 사물 **3갈래**로 나눠, 텍스트가 이미지를 참고해 스스로 보정.


공통점(중요) — 이미지를 늘 **전체 한 덩어리(global)**로만 본다. “어디를 보는가”는 아무도 안 건드렸다.



손대는 건 전부 **텍스트 쪽** — 이미지 표현 자체는 끝까지 전역.

단서는 사진의 특정 부분에 있다

거의 모든 모델




이미지 = 전체

이미지는 전체로 두고, 손대는 건 텍스트뿐.

텍스트만 손봄



그런데 ②의 단서는...



단면 = 특정 부분

거길 봐야 하지 않나? = 이미지 쪽을 국소화(localize)하자.

잘린? 깎둑썬?

→ 단면을 봐야 인

가설의 씨앗 — 아무도 건드리지 않은 '이미지 국소화' 축.

하나의 문장을 따라간 세 번의 시도

관통하는 한 문장

“정답은 top-5 안에 있는데, top-1을 못 고른다.”

① **지식을 더 넣자** — 바깥 지식을 주입해 정보 부족을 메우자

• 실패

② **top-5에서 골라내자** — 후보를 사후에 다시 순위 매기자

• 실패

③ **처음부터 top-1을 맞히게** — ‘어디를 볼지’를 고치자 **(PGAL)**

• 진행 중

"지식을 더 넣으면?" — 16축 전부 기각

가설 — 정보가 부족한 게 문제다 → 바깥 지식을 주입하자.


대표 시도 — v3_text

LLM 설명("젖은 강아지는 털이 뭉치고 어둡다")을 텍스트에 주입 → **효과 없음** (데이터셋 2개 모두 하락).

- 더 **세게** 줄수록 오히려 더 나빠짐 (개입 강도 ↑ → 성능 ↓)
- 그 외 **11개 변형**도 전부 노이즈 수준 — 의미 있는 개선 0

사전등록된 **16축 체계적 검증** → 전부 기각. "지식 추가는 막다른 길."


개입 강도 ↑ → 성능 변화



강하게 개입할수록 더 깊이 음수 — gap은 '지식'으로 안 닫힌다.

병목은 '지식'이 아니라 '어디를 보느냐'

모델 분석 — 같은 모델, 두 척도




정답을 5개 안엔 넣어두지만, 1등 고를 때 형제끼리 헛갈린다.

시도 (F) — top-5 재선택

5개 후보를 LLM이 다시 고르게 → **실패** (고친 만큼 다른 걸 망가뜨림).

진단 — 병목은 지식 부족이 아니라 같은 사물 아래 **형제 상태의 시각 granularity**. 즉, “어디를 보느냐”의 문제.

PGAL — 속성이 나타난 곳을 콕 집어 본다



사후 보정 대신, **처음부터 속성 발현 영역(단면·녹)**을 콕 집어 본다.

- **역할 분리** — 사물은 전체로, 속성은 국소로
- attention map = **해석 가능** (어디 보고 판단했는지)


차별점 — 기존 = 이미지 전역, PGAL = 이미지 국소화. 아무도 안 건드린 축.

z_a = 속성을 보기 위한 지역(local) 이미지 표현.

첫 긍정 신호 — non-regression

	본 조합	안 본 조합	균형 (HM)
Troika (baseline)	0.489	0.524	0.390
PGAL (제안)	0.468	0.533	0.388

$\Delta \text{HM} \approx 0$ — 시드만 바뀌도 생기는 노이즈 대역 안



non-regression = 새 메커니즘을 넣어도 기존 성능을 (노이즈 이상으로) 깎지 않음.

앞선 **16개 시도**는 대부분 이걸 못 하고 성능을 떨어뜨렸다 — PGAL은 깎지 않았다 → **첫 긍정 신호**.

단, "안 깨짐"이 곧 "일을 함"은 아니다 — 그래서 다음 장에서 정직하게 검증한다.

국소화가 진짜 작동하나 — 3종 검증

ablation (국소화 제거) 국소화를 끄면 점수가 내려간다 → 국소화가 **점수에 기여**

• 약한 +

attention 시각화 맵이 단면이 아니라 아직 **배경을 본다** → 정성 신호 미흡

• 아직 배경

F-probe 오라클 형제 변별을 복구하나? → 고친 만큼 망가뜨려 **차이 0**

• 차이 0

정직한 결론

“표현은 안 깨뜨리지만, 형제 변별 복구는 아직 미입증.”

점수 동물에 안 속고 메커니즘까지 검증한 것 — 이 자체가 강점.

실패의 나열이 아니라 진단 주도 수렴

01

체계적 negative

incremental 개입은 무효 — 사전등록 16축으로 “gap은 안 닫힌다”를 통제 실험으로 입증.

02

병목 진단

병목을 ‘어디를 보느냐’(형제 상태의 시각 granularity)로 특정.

03

새 축 제안

이미지 국소화(PGAL) + 첫 non-regression + 해석 가능성.

향후

국소화가 **올바른 영역**을 보게 하는 장치(attention 정렬) — 또는 차순위 축(속성을 연산자로 보는 생성 접근).