

• 중간 발표 · Research Progress

PGAL

Patch-Grounded Attribute Localization

이미지 Localization 기반 CZSL 메커니즘 탐색

“기존 CZSL이 **텍스트를 적응**시킬 때, 우리는 **이미지를 Localize**한다”

KimDongKi

한양대학교 MMAI LAB · 2026. 06. 02

Compositional Zero-Shot Learning

- 속성(attribute) × 객체(object)의 조합을 인식
- 학습 때 보지 못한 조합까지 맞히는 것이 목표
- 속성·객체(primitive)는 봤지만, 그 조합은 처음 — 재조합 일반화

핵심 질문 — “빨강도 알고 토마토도 아는데, red tomato를 한 번도 본 적 없을 때 맞힐 수 있는가?”

학습에서 본 조합 (SEEN)

red apple
green tomato
sliced apple

테스트 — 처음 보는 조합 (UNSEEN)

red tomato ?
sliced tomato ?

→ primitive를 분해하고 재조합(compositional generalization)

어떻게 평가하나

데이터셋

MIT-States — 115 attr × 245 obj, 자연 이미지 (주 벤치마크)

UT-Zappos — 신발 도메인, fine-grained (전이 검증)

분할 (Split)


Seen pairs(학습) vs **Unseen pairs**(테스트 전용)

Closed-world — 실재 조합으로 후보 제한 / **Open-world** — 전체 attr×obj

지표

Seen acc · Unseen acc · **HM**(둘의 조화평균, 균형) ·

AUC(bias-sweep 면적, 핵심)



seen ↔ unseen은 **trade-off** — 한쪽을 올리면 다른 쪽이 내려간다. HM·AUC로 균형을 본다.

CZSL의 3대 난점

1 맥락 의존성

같은 wet도 wet dog / wet forest / wet sand에서 시각적으로 전혀 다름 — primitive가 객체에 entangle


2 형제 상태(sibling-state) 변별 • 뒤 진단의 핵심

sliced vs diced, caramelized vs molten 같은 미세한 시각 차이

3 Unseen 일반화

seen 조합에 과적합하면 unseen이 붕괴 — seen-unseen trade-off가 본질


①의 예시 — 같은 속성, 다른 모습



wet dog



wet forest



wet sand

현 주류 — 텍스트를 적응시키는 계보

모델	핵심 아이디어	위치
CLIP zero-shot	"a photo of [attr] [obj]" 프롬프트로 그대로 매칭	출발점
CoOp → CSP	프롬프트를 학습 가능한 soft / composable token으로	프롬프트 학습
DFSP	조합을 attr/obj로 분해 후 cross-modal 융합	분해·융합
Troika (CVPR' 24)	Multi-branch + CMT — 텍스트가 이미지 patch에 cross-attend	본 연구 baseline
ClusPro (ICLR' 25)	primitive마다 다중 프로토타입 클러스터	정식 게재 SOTA

공통점 — 이미지는 전역(CLS), 텍스트·프로토타입만 적응시킨다. 이것이 다음 장 ‘빈틈’의 근거가 된다.

“두 갈래” 지형 — 그리고 왜 Troika인가

계보	대표	AUC	HM
Prototype	ClusPro '25	0.238	0.407
Troika-확장	Troika '24	0.221	0.393
	LOGICZSL '25	0.234	0.405

MIT-States Closed-world · 소수 통일 (0.407 = 40.7%)


- 동시기 연구(ICLR 2월 vs CVPR 제출 전년 11월) → 서로 비교 없이 각자 “SOTA” 주장
- LOGICZSL(CVPR'25)조차 ClusPro를 빼고 Troika 기준으로 SOTA 주장
- → Troika는 가장 널리 확장되는 표준 reference framework

∴ Troika를 baseline으로 삼은 것은 분야 표준에 부합 — “왜 ClusPro가 아닌가”에 대한 선제 답변.

비어 있는 축 — Image-side Localization

기존 — 텍스트를 적응시킨다


IMAGE



전역 CLS


CMT조차 결국 보정된 텍스트 · **전역 CLS**로 채점 — 이미지는 끝까지 global.

TEXT



제안 — 이미지를 Localize한다


IMAGE



local z_a

이미지 표현 자체를 Localize하는 축은 아무도 건드리지 않았다.

TEXT



외부지식·표현 강화 — 10개 변형, 전부 기각

- A 의미지식
- B vision
- C loss
- D prototype
- E 운영

축	메커니즘	결과 (Δ HM)
A. LLM 의미지식 7		
v3_text	LLM description → 텍스트 prompt 결합	-0.027 / -0.053
image_cond	image-conditional softmax aggregation	-0.029 · fail
feasibility	feasibility 점수 → comp logit prior (open-world)	신호 없음 · 봉인
C'	logic-rule — attr 배타 + 비양립 (0.2%)	-0.0009 · fail
D'	semantic hard-negative InfoNCE (0.8%)	+0.0011 · tie
E	taxonomy aux CE — state-group / super-cat (3.3%, 최강)	-0.012 · worst
F	multimodal test-time rerank (inference)	net -0.02
B. Vision-side 3		
R2D2	spatial-richness를 vision-side로 distill	+0.0039 · tie
imgsel	image-conditional feature 선택	-0.059 · fail
vision_distill	R2D2 distill-only — routing 제거	-0.015

Δ는 각 framework baseline 기준 (LHP 0.3887 / Troika 0.3899·0.3940) · 전부 실행 완료한 실험.

구조·loss·운영 — 6개 변형, 그리고 결론

A 의미지식 / B vision / C loss / D prototype / E 운영

축	메커니즘	결과
C. Loss 2		
cosface	CosFace cosine margin (val +0.020, test 실패)	-0.0124 · fail
hardpair	same-primitive hard pair + contrastive	-0.0049 · tie
D. Prototype 2		
OT-LHP	Sinkhorn prototype assignment (ClusPro)	-0.0012 · dead
OT-Troika	동일 OT → Troika 이식 (둘 다 죽음)	-0.0073 · dead
E. 체크포인트 2		
ckpt-ensemble	multi-epoch 앙상블 (H2)	+0.0037 · tie
ckpt-selection	best_loss vs best_hm (cutoff 미달)	+0.0094 · 미달

Δ는 각 framework baseline 기준 (LHP 0.3887 / Troika 0.3899·0.3940) · 전부 실행 완료한 실험.

결론

- 16변형 전부 실행 → 효과 0~음수, 전부 봉인
- 최고치도 R2D2 +0.0039 / ensemble +0.0037 — cutoff +0.005 미달
- bite↑에도 음수(E -0.012 최악) → gap은 architectural

The bottleneck isn't "knowledge" — it's "where to look"

0.286

top-1 정확도



0.606


gt가 top-5 안에 들 확률

표현은 정답을 **top-5까지 끌어올리지만**, top-1에서 형제 상태를 못 가린다.

- 실패의 정체 = **sibling-state 혼동** (caramelized ↔ molten 등)
- 병목 = 같은 객체 아래 형제 상태의 **시각적 granularity**

16축의 실패가 여기로 수렴 — "텍스트 지식이 아니라 **시각 위치**가 문제."

PGAL — Patch-Grounded Attribute Localization



속성이 발현된 영역으로 표현을 **Localize**해, 그 영역에서 속성을 채점한다.


- attention map = **해석 가능** (어디 보고 판단했는지)
- entropy 정규화는 **train-only** → eval 선택에 confound 0

목표 재정의 — SOTA 추격 X. **novel + defensible + non-regression**이면 기여.

첫 non-regression

	seen	unseen	HM	AUC
Troika baseline (3-seed)	0.489	0.524	0.3899 ±0.0038	0.2177
PGAL (seed0)	0.468	0.533	0.3878	0.2127

Δ HM = -0.0021 — 시드 노이즈 대역(± 0.0038) 안



non-regression 통과 — §20 4축이 전부 fail/null 이었던 것과 대조 (E taxonomy는 -0.012 fail).

솔직히 — 아직 숫자를 올린 메커니즘은 없다. 핵심은 “차별 축 + 표현을 안 깨뜨림.”

성능 초과가 목표가 아니라 **차별 메커니즘 검증**이 목표(슬라이드 10 재정의).

메커니즘은 실제로 작동하는가

(b) Ablation — uniform attention

attention을 mean-pool로 강제해 **Localization**만 제거. PGAL > uniform이면 Localization 기여 입증.

• 학습 중 · ETA 오늘

HM ---


(c) Attention map 시각화

rust 영역 · cut 단면 · moisture 등 **의미 있는 영역**을 짚는지 정성 검증.

(d) F-probe 오라클

PGAL이 진단했던 **sibling-state** 혼동을 실제로 복구하는지 정량.

(c) attention heatmap



viz 산출 후 삽입

수치가 노이즈 안이므로 — “메커니즘이 작동한다”가 유일하고 핵심적인 방어선.

향후 계획

- 통과 시 **Stage 2** — 3-seed 안정성 확인 + **UT-Zappos 전이**(도메인 일반성). attention map 정성 + sibling-state 복구율을 논문 그림으로.
- 진행 **C' 재검토** — LOGICZSL식 **staged-logic**(3종 분해 + warmup 후 단계 투입 + $q=3.0$)으로 봉인 축의 구현 차이 재확인.
- fallback **차순위 축** — (II) Attributes-as-operators 부활 → (IV) generative unseen-feature synthesis → (III) ordinal state는 regularizer로 흡수.

결론

01

체계적 negative

사전등록된 incremental 16축으로 “gap은 안 닫힌다 (EV≈0)”를 통제 실험으로 입증.

02

병목 진단

F-probe로 병목을 **visual granularity**(형제 상태)로 특정.

03

차별 축 제안

image-side localization(PGAL) + 첫 non-regression + 해석 가능성.

“실패의 나열이 아니라 **진단 주도 수렴** — negative → 진단 → 차별 메커니즘.”