

• 중간 발표 · Research Progress

PGAL

Patch-Grounded Attribute Localization

이미지 Localization 기반 CZSL 메커니즘 탐색

“기존 CZSL이 **텍스트를 적응**시킬 때, 우리는 **이미지를 Localize**한다”

이 발표는 “**SOTA를 이겼다**”가 아니라 — 왜 안 되는지 체계적으로 진단하고, 아무도 안 건드린 축(이미지 Localization)을 제안하는 진단-주도 연구입니다.

KimDongKi

한양대학교 MMAI LAB · 2026. 06. 02

Compositional Zero-Shot Learning

- 속성(attribute) × 객체(object)의 조합을 인식
- 학습 때 보지 못한 조합까지 맞추는 것이 목표
- 속성·객체(primitive)는 봤지만, 그 조합은 처음 — 재조합 일반화

핵심 질문 — “빨강도 알고 토마토도 아는데, red tomato를 한 번도 본 적 없을 때 맞힐 수 있는가?”

학습에서 본 조합 (SEEN)

red apple
green tomato
sliced apple

테스트 — 처음 보는 조합 (UNSEEN)

red tomato ?
sliced tomato ?

→ primitive를 분해하고 재조합(compositional generalization)

어떻게 평가하나

데이터셋

MIT-States — 115 attr × 245 obj, 자연 이미지 (주 벤치마크)

UT-Zappos — 신발 도메인, fine-grained (전이 검증)

분할 (Split)

Seen pairs(학습) vs **Unseen pairs**(테스트 전용)


Closed-world — 실재 조합으로 후보 제한 / **Open-world** — 전체 attr×obj

지표

Seen acc · Unseen acc · **HM**(둘의 조화평균, 균형) ·

AUC(bias-sweep 면적, 핵심)

AUC = seen 선호도(bias)를 0→최대로 켜어가며 그린 seen-unseen 곡선의 아래 면적 — 한 점이 아니라 전 구간 성능을 한 숫자로.



seen ↔ unseen은 **trade-off** — 한쪽을 올리면 다른 쪽이 내려간다. HM·AUC로 균형을 본다.

CZSL의 3대 난점

1 맥락 의존성

같은 wet도 wet dog / wet forest / wet sand에서 시각적으로 전혀 다름 — primitive가 객체에 entangle


2 형제 상태(sibling-state) 변별 • 뒤 진단의 핵심

sliced vs diced, caramelized vs molten 같은 미세한 시각 차이

3 Unseen 일반화

seen 조합에 과적합하면 unseen이 붕괴 — seen-unseen trade-off가 본질


①의 예시 — 같은 속성, 다른 모습



wet dog



wet forest



wet sand

현 주류 — 텍스트를 적응시키는 계보

모델	핵심 아이디어	위치
CLIP zero-shot	"a photo of [attr] [obj]" 프롬프트로 그대로 매칭	출발점
CoOp → CSP	프롬프트를 학습 가능한 soft / composable token으로	프롬프트 학습
DFSP	조합을 attr/obj로 분해 후 cross-modal 융합	분해·융합
Troika (CVPR' 24)	Multi-branch + CMT — 텍스트가 이미지 patch에 cross-attend	본 연구 baseline
ClusPro (ICLR' 25)	primitive마다 다중 프로토타입 클러스터	정식 게재 SOTA

공통점 — 이미지는 전역(CLS), 텍스트·프로토타입만 적응시킨다. 이것이 다음 장 ‘빈틈’의 근거가 된다.

CMT = Cross-Modal Transformer (텍스트가 이미지 patch에 attend) · CLS = ViT가 이미지를 통째로 요약한 전역 토큰(위치 정보 없음).

“두 갈래” 지형 — 그리고 왜 Troika인가

계보	대표	AUC	HM
Prototype	ClusPro '25	0.238	0.407
Troika-확장	Troika '24	0.221	0.393
	LOGICZSL '25	0.234	0.405

MIT-States Closed-world · AUC·HM 모두 높을수록 좋음 (0.407 = 40.7%)

※ 0.40대가 낮아 보여도 CZSL(처음 보는 조합)에선 이 대역이 정상 SOTA.


- 동시기 연구(ICLR 2월 vs CVPR 제출 전년 11월) → 서로 비교 없이 각자 “SOTA” 주장
- LOGICZSL(CVPR'25)조차 ClusPro를 빼고 Troika 기준으로 SOTA 주장
- → Troika는 가장 널리 확장되는 표준 reference framework

∴ Troika를 baseline으로 삼은 것은 분야 표준에 부합 — “왜 ClusPro가 아닌가”에 대한 선제 답변.

비어 있는 축 — Image-side Localization

기존 — 텍스트를 적응시킨다


IMAGE



전역 CLS


CMT조차 결국 보정된 텍스트 · **전역 CLS**로 채점 — 이미지는 끝까지 global.

TEXT



제안 — 이미지를 Localize한다

IMAGE



local z_a

TEXT



이미지 표현 자체를 Localize하는 축은 아무도 건드리지 않았다.

외부지식·표현 강화 — 10개 변형, 전부 기각

- A 의미지식
- B vision
- C loss
- D prototype
- E 운영

축	메커니즘	결과 (Δ HM)
A. LLM 의미지식 7		
v3_text	LLM description → 텍스트 prompt 결합	-0.027 / -0.053
image_cond	image-conditional softmax aggregation	-0.029 · fail
feasibility	feasibility 점수 → comp logit prior (open-world)	신호 없음 · 봉인
C'	logic-rule — attr 배타 + 비양립 (0.2%)	-0.0009 · fail
D'	semantic hard-negative InfoNCE (0.8%)	+0.0011 · tie
E	taxonomy aux CE — state-group / super-cat (3.3%, 최강)	-0.012 · worst
F	multimodal test-time rerank (inference)	net -0.02
B. Vision-side 3		
R2D2	spatial-richness를 vision-side로 distill	+0.0039 · tie
imgsel	image-conditional feature 선택	-0.059 · fail
vision_distill	R2D2 distill-only — routing 제거	-0.015

Δ HM = baseline 대비 변화량 (+개선 / -악화 / 0~동률) · 각 framework baseline 기준 (LHP 0.3887 / Troika 0.3899·0.3940).

v3_text·C'·D'·E·F 등은 사전등록 실험 번호 — 메커니즘(가운데 칸)만 보면 됩니다. tie=무효 · fail=하락 · 봉인=폐기 확정.

구조·loss·운영 — 6개 변형, 그리고 결론

A 의미지식 / B vision / C loss / D prototype / E 운영

축	메커니즘	결과
C. Loss 2		
cosface	CosFace cosine margin (val +0.020, test 실패)	-0.0124 · fail
hardpair	same-primitive hard pair + contrastive	-0.0049 · tie
D. Prototype 2		
OT-LHP	Sinkhorn prototype assignment (ClusPro)	-0.0012 · dead
OT-Troika	동일 OT → Troika 이식 (둘 다 죽음)	-0.0073 · dead
E. 체크포인트 2		
ckpt-ensemble	multi-epoch 앙상블 (H2)	+0.0037 · tie
ckpt-selection	best_loss vs best_hm (cutoff 미달)	+0.0094 · 미달

Δ HM = baseline 대비 변화량 (+개선 / -악화 / 0~동률) · 각 framework baseline 기준 (LHP 0.3887 / Troika 0.3899·0.3940).

bite = 개입 강도(0.2%→3.3%) · OT = Optimal Transport(프로토타입 배정) · dead = 양쪽 프레임워크 모두 효과 없음.

결론

- 16변형 전부 실행 → 효과 0~음수, 전부 봉인
- 최고치도 **R2D2 +0.0039 / ensemble +0.0037** — cutoff +0.005 미달
- bite↑에도 음수(E -0.012 최악) → gap은 **architectural**

The bottleneck isn't "knowledge" — it's "where to look"

0.286

top-1 정확도



0.606


gt가 top-5 안에 들 확률

표현은 정답을 **top-5까지 끌어올리지만**, top-1에서 형제 상태를 못 가린다.

- 실패의 정체 = **sibling-state 혼동** (caramelized ↔ molten 등)
- 병목 = 같은 객체 아래 형제 상태의 **시각적 granularity**

16축의 실패가 여기로 수렴 — "텍스트 지식이 아니라 **시각 위치**가 문제."

PGAL — Patch-Grounded Attribute Localization



속성이 **발현된 영역으로 표현을 Localize**해, 그 영역에서 속성을 채점한다.

- attention map = **해석 가능** (어디 보고 판단했는지)
- entropy 정규화는 **train에서만** 사용 → 평가 점수를 부풀리지 않음(공정)


목표 재정의 — SOTA 추격 X. **novel + defensible + non-regression**이면 기여.

z_a = 속성을 보기 위한 지역(local) 이미지 표현 — 전역 CLS와 대비.

첫 non-regression

	seen	unseen	HM	AUC
Troika baseline (3-seed)	0.489	0.524	0.3899 ±0.0038	0.2177
PGAL (seed0)	0.468	0.533	0.3878	0.2127

Δ HM = -0.0021 — 시드 노이즈 대역(± 0.0038) 안



앞 시도들은 성능을 깎았지만(-), PGAL은 깎지 않았다(≈ 0) — 그래서 **동물이 곳 진전**.

non-regression = 새 메커니즘을 넣어도 기존 성능을 (노이즈 이상으로) 깎지 않음.

→ 앞서 본 **16개 시도**는 대부분 이걸 못 하고 성능을 떨어뜨렸다 (E taxonomy -0.012 fail).

Δ HM -0.0021 = 시드만 바뀌도 생기는 노이즈(± 0.0038) 안 → **사실상 동물 = 통과**.

솔직히 — 아직 숫자를 올린 메커니즘은 없다. 핵심은 “차별 축을 심 으면서 표현을 안 깨뜨렸다.”

메커니즘은 실제로 작동하는가

(b) Ablation — uniform attention

• 완료

attention을 mean-pool로 강제해 **Localization**만 제거

+0.0047

$\Delta\text{HM} \cdot \Delta\text{AUC} +0.0014$

(c) Attention map 시각화

• 아직 거침

맵이 **배경 지향** — 정성 신호는 아직 약함(정직하게 표기).

(d) F-probe 오라클

• 예정

PGAL이 진단했던 **sibling-state** 혼동을 실제로 복구하는지 정량.

(b) Ablation — MIT-States CW · seed0

	HM	AUC
PGAL (localization)	0.3878	0.2127
uniform (ablation)	0.3831	0.2113

국소화가 점수에 기여(+방향) — 단 ΔHM 은 1-seed 노이즈 (± 0.0038) 바로 바깥, 3-seed로 굳힐 것.

정량 ablation은 + 방향(국소화 기여), 정성 맵은 아직 거칠다 — 정직하게.

향후 계획

- **통과 시** **Stage 2** — 3-seed 안정성 확인 + **UT-Zappos 전이**(도메인 일반성). attention map 정성 + sibling-state 복구율을 논문 그림으로.
- **진행** **C' 재검토** — LOGICZSL식 **staged-logic**(단계적 logic 투입 방식)으로 봉인 축의 구현 차이 재확인.
- **fallback** **차순위 축** — 속성을 연산자로 보는 접근 → unseen feature 생성 → ordinal state는 regularizer로 흡수.

결론

01

체계적 negative

사전등록된 incremental 16축으로 “gap은 안 닫힌다(추가 효과 ≈ 0)”를 통제 실험으로 입증.

02

병목 진단

F-probe로 병목을 **visual granularity**(형제 상태)로 특정.

03

차별 축 제안

image-side localization(PGAL) + 첫 non-regression + 해석 가능성.

“실패의 나열이 아니라 **진단 주도 수렴** — negative → 진단 → 차별 메커니즘.”